

Taller 1: Recolección de datos, web scraping y construcción de base SQLite

Luisa Fernanda Guerrero Ordoñez

2026

1. Introducción

Para el desarrollo del presente taller se seleccionó la revista científica **Big Data and Cognitive Computing**, una revista indexada en cuartil Q1. Esta revista se especializa en áreas relacionadas con inteligencia artificial, minería de datos, aprendizaje automático, big data, analítica avanzada y sistemas cognitivos, temáticas que se encuentran directamente relacionadas con los contenidos abordados en la materia.

La revista pertenece a la editorial MDPI y cuenta con acceso público a los artículos y metadatos de sus publicaciones.

El enlace principal utilizado fue:

- <https://www.mdpi.com/journal/bdcc>

Adicionalmente, para localizar los artículos publicados durante el año 2025 se utilizó la sección de números y volúmenes:

- <https://www.mdpi.com/journal/bdcc/issues/2025>

La elección de esta revista se realizó porque sus publicaciones están relacionadas con temas propios de minería de datos, inteligencia artificial, aprendizaje automático y analítica de datos. Además de que el sitio web tiene una estructura organizada por volúmenes, números y artículos individuales, lo cual facilita el proceso de extracción automatizada de los datos y la posterior construcción de una base de datos relacional.

2. Fuente de datos y scraping

La fuente de datos corresponde al portal oficial de la revista **Big Data and Cognitive Computing** de MDPI. Para el scraping se trabajó con los artículos publicados en el volumen 9, correspondiente al año 2025.

El proceso consistió en:

1. Recorrer los números publicados en 2025.
2. Extraer los enlaces individuales de los artículos.
3. Visitar cada artículo.
4. Extraer metadatos como título, autores, fecha, DOI, URL, resumen, referencias y métricas disponibles.
5. Construir archivos auxiliares en formato CSV y JSON.
6. Crear una base de datos SQLite con tablas relacionales.

2.1 Desarrollo del scraping y construcción de la base

2.2 Librerías utilizadas

Para realizar el scraping y la construcción de la base de datos se usaron librerías de R orientadas a la lectura de páginas web, manipulación de datos y conexión con SQLite. Las principales fueron `rvest`, `httr`, `dplyr`, `stringr`, `tidyr`, `DBI` y `RSQLite`.

`rvest` permitió leer y extraer elementos del HTML, mientras que `httr` se utilizó para hacer solicitudes HTTP más controladas. Las librerías `dplyr`, `tidyr` y `stringr` facilitaron la limpieza y transformación de datos. Finalmente, `DBI` y `RSQLite` permitieron crear la base de datos relacional.

2.3 Estrategia de extracción

La extracción se hizo de manera secuencial. Lo que quiere decir que primero se construyeron las URL de los números de la revista correspondientes al año 2025. Luego desde cada número se extrajeron los enlaces individuales de los artículos y al final cada artículo fue “visitado” podríamos decir, para recolectar sus metadatos principales.

Durante el proceso se utilizaron encabezados HTTP similares a los de un navegador. Esta decisión se tomó porque como se mencionó en clase algunas páginas pueden rechazar solicitudes automáticas muy simples o demasiado rápidas. También se aplicaron pausas entre solicitudes para evitar sobrecargar el sitio web y reducir el riesgo de bloqueo temporal.

Los datos extraídos fueron: título, autores, fecha de publicación, DOI, URL, resumen, número de citas, visualizaciones, descargas y lista de referencias.

2.4 Clasificación temática

Cada artículo fue clasificado en una categoría temática mediante un criterio reproducible basado en palabras clave presentes en el título y en el resumen. Las categorías utilizadas fueron:

- **Machine Learning**
- **IA Generativa**
- **Estadística**
- **Otros**

La clasificación se realizó mediante reglas condicionales. Por ejemplo, si el título o resumen contenía expresiones como *machine learning*, *deep learning*, *neural network*, *classification* o *prediction*, el artículo se clasificó como **Machine Learning**. Si contenía palabras como *generative*, *LLM*, *ChatGPT*, *prompt*, *diffusion* o *GPT*, se clasificó como **IA Generativa**. Para **Estadística** se usaron términos como *regression*, *probability*, *bayesian*, *variance* o *correlation*. Los artículos que no coincidieron con estas reglas se ubicaron en **Otros**.

Table 1: Distribución de artículos según la clasificación temática

topic_label	cantidad_articulos
Machine Learning	173
IA Generativa	70
Otros	58
Estadística	15

2.5 Manejo de valores faltantes

Durante la extracción se encontraron algunos valores faltantes especialmente en las variables relacionadas con citas y visualizaciones. Esto ocurrió porque este tipo de métricas no siempre se encuentra disponible directamente en el HTML estático de cada artículo. En algunos casos estas métricas pueden cargarse por medio de servicios internos de la página o no estar publicadas de forma visible.

Por esta razón lo que se decidió fue conservar esos valores como NA. Esto evita inventar datos o completar información sin un respaldo. En cambio permite diferenciar entre los datos que fueron extraídos directamente y aquellos que no estuvieron disponibles durante el scraping.

En el caso de las referencias bibliográficas la extracción fue más completa ya que la mayoría de artículos presentaban esta información dentro de la página del artículo, por eso se decidió almacenar las referencias en una tabla independiente.

Table 2: Resumen general de la extracción de datos

indicador	valor
Artículos extraídos	316
Autores registrados en artículos	1250
Referencias extraídas	18207
Artículos sin citas	316
Artículos sin visualizaciones	316
Artículos sin descargas	4
Archivo SQLite	output/bdcc_2025.sqlite
Archivo SQL	output/bdcc_2025_schema.sql

2.6 Vista parcial del dataset

A continuación se presenta una vista parcial del conjunto de datos construido a partir del scraping. Esta tabla permite observar algunos de los campos principales que fueron almacenados para cada artículo.

Table 3: Vista parcial de los artículos extraídos

title	publication_id	doi	date	n_authors	downloads	references	topic_label
MobileNet-HeX: Heterogeneous Ensemble of MobileNet eXperts for Efficient and Scalable Vision Model Optimization	2025/1	10.3390/bdcc90100020	2025-01-01	10	100020	37	Machine Learning
Cognitive Method for Synthesising a Fuzzy Controller Mathematical Model Using a Genetic Algorithm for Tuning	2025/1	10.3390/bdcc90100170	2025-01-01	10	100170	100	Otros
AI-Driven Mental Health Surveillance: Identifying Suicidal Ideation Through Machine Learning Techniques	2025/1	10.3390/bdcc90100160	2025-01-01	10	100160	30	Machine Learning
Eliciting Emotions: Investigating the Use of Generative AI and Facial Muscle Activation in Children’s Emotional Recognition	2025/1	10.3390/bdcc90100150	2025-01-01	10	100150	56	IA Generativa
A Secure Learned Image Codec for Authenticity Verification via Self-Destructive Compression	2025/1	10.3390/bdcc90100140	2025-01-01	10	100140	63	Otros
Predicting Intensive Care Unit Admissions in COVID-19 Patients: An AI-Powered Machine Learning Model	2025/1	10.3390/bdcc90100130	2025-01-01	10	100130	72	Machine Learning

title	publication_id	date	n_authors	downloads	references	topic_label
Quantum-Cognitive Neural Networks: Assessing Confidence and Uncertainty with Human Decision-Making Simulations	2025/1	10.3390/bdcc90100120	90	117	Machine Learning	Machine Learning
The Data Heterogeneity Issue Regarding COVID-19 Lung Imaging in Federated Learning: An Experimental Study	2025/1	10.3390/bdcc90100110	90	52	Otros	Otros
SqueezeMaskNet: Real-Time Mask-Wearing Recognition for Edge Devices	2025/1	10.3390/bdcc90100100	90	27	Machine Learning	Machine Learning
DRCCT: Enhancing Diabetic Retinopathy Classification with a Compact Convolutional Transformer	2025/1	10.3390/bdcc90100090	90	30	Machine Learning	Machine Learning

3. Construcción de la base de datos SQLite

Después de obtener y limpiar los datos se construyó una base de datos SQLite. Se decidió utilizar una estructura relacional porque la información de los artículos, autores y referencias tiene relaciones de uno a muchos y muchos a muchos.

Por ejemplo un artículo puede tener varios autores y un autor puede aparecer en varios artículos. De la misma forma un artículo puede tener muchas referencias bibliográficas por lo que no era conveniente almacenar toda la información en una única tabla.

3.1 Tablas creadas

La base de datos contiene las siguientes tablas:

- **papers:** almacena la información principal de cada artículo.
- **authors:** almacena los autores únicos.
- **paper_authors:** relaciona artículos con autores.
- **references_table:** almacena referencias únicas.
- **paper_references:** relaciona artículos con sus referencias.

3.1.1 Tabla principal: papers

La tabla principal de la base de datos corresponde a **papers** esto se adopto por sugerencia del taller. Esta tabla almacena la información general de cada artículo científico extraído desde la revista *Big Data and Cognitive Computing*.

Cada registro representa un artículo individual y contiene tanto metadatos bibliográficos como variables derivadas durante el proceso de análisis y clasificación por temática.

Las columnas almacenadas fueron las siguientes:

Columna	Descripción
paper_id	Identificador único del artículo
journal_name	Nombre de la revista
title	Título del artículo
publication_date	Fecha de publicación

Columna	Descripción
year	Año de publicación
doi	DOI del artículo
url	Enlace del artículo
abstract	Resumen del artículo
authors_raw	Lista de autores en formato texto
n_authors	Número de autores
citations	Número de citas extraídas
downloads	Número de descargas
n_references	Cantidad de referencias bibliográficas
topic_label	Clasificación temática del artículo

A continuación se muestra una vista parcial de la tabla **papers** obtenida directamente desde SQLite.

Table 5: Vista parcial de la tabla papers

paper_id	journal_name	title	publication_year	year_date	n_authors	downloads	citations	topic_label
1	Big Data and Cognitive Computing	MobileNet-HeX: Heterogeneous Ensemble of MobileNet eXperts for Efficient and Scalable Vision Model Optimization	2025/1	202510.3390/bd4c9010002	37	Machine Learning		
2	Big Data and Cognitive Computing	Cognitive Method for Synthesising a Fuzzy Controller Mathematical Model Using a Genetic Algorithm for Tuning	2025/1	202510.3390/bd4c9010017	100	Otros		
3	Big Data and Cognitive Computing	AI-Driven Mental Health Surveillance: Identifying Suicidal Ideation Through Machine Learning Techniques	2025/1	202510.3390/bd5c9010016	30	Machine Learning		
4	Big Data and Cognitive Computing	Eliciting Emotions: Investigating the Use of Generative AI and Facial Muscle Activation in Children’s Emotional Recognition	2025/1	202510.3390/bd5c9010015	56	IA Generativa		
5	Big Data and Cognitive Computing	A Secure Learned Image Codec for Authenticity Verification via Self-Destructive Compression	2025/1	202510.3390/bd2c9010014	63	Otros		
6	Big Data and Cognitive Computing	Predicting Intensive Care Unit Admissions in COVID-19 Patients: An AI-Powered Machine Learning Model	2025/1	202510.3390/bd4c9010013	72	Machine Learning		
7	Big Data and Cognitive Computing	Quantum-Cognitive Neural Networks: Assessing Confidence and Uncertainty with Human Decision-Making Simulations	2025/1	202510.3390/bd2c9010012	117	Machine Learning		

paper_id	journal_name	title	publication_year	year_date	n_authors	downloads	references	topics	label
8	Big Data and Cognitive Computing	The Data Heterogeneity Issue Regarding COVID-19 Lung Imaging in Federated Learning: An Experimental Study	2025/1	202510.3390/bd2c9010011	52	Otros			
9	Big Data and Cognitive Computing	SqueezeMaskNet: Real-Time Mask-Wearing Recognition for Edge Devices	2025/1	202510.3390/bd4c9010010	27	Machine Learning			
10	Big Data and Cognitive Computing	DRCCT: Enhancing Diabetic Retinopathy Classification with a Compact Convolutional Transformer	2025/1	202510.3390/bd5c9010009	30	Machine Learning			

Table 6: Cantidad de registros por tabla en la base SQLite

tabla	registros
papers	316
authors	1163
paper_authors	1250
references_table	17953
paper_references	18207

3.2 Justificación del modelo relacional

La tabla **papers** contiene los metadatos generales de cada artículo, como título, fecha, DOI, URL, resumen, número de autores, referencias y categoría temática. La tabla **authors** permite evitar la repetición de nombres de autores, mientras que **paper_authors** conserva la relación entre artículos y autores incluyendo el orden de aparición.

Las referencias se almacenaron en **references_table** y se relacionaron con los artículos mediante **paper_references**. Esta separación permite consultar posteriormente qué referencias pertenecen a cada artículo y evita almacenar listas largas dentro de una sola celda.

4. Archivos generados

Como resultado del proceso se generaron varios archivos de salida en la carpeta **output**:

- **bdcc_articulos_2025.csv**
- **bdcc_referencias_2025.csv**
- **bdcc_articulos_2025.json**
- **bdcc_2025.sqlite**
- **bdcc_2025_schema.sql**

El archivo **.csv** contiene los artículos en formato tabular, el archivo **.json** conserva la estructura completa de los datos extraídos y el archivo **.sqlite** contiene la base de datos relacional. También se generó un archivo **.sql** con la estructura de creación de tablas.

5. Preguntas a responder con SQL

En esta sección se ejecutan consultas SQL sobre la base de datos `bdcc_2025.sqlite`. Cada consulta corresponde a responder una pregunta del taller a partir de la información almacenada en las tablas que se contruyeron previamente.

5.1 ¿Cuál es el número promedio de autores por paper?

```
consulta_1 <- dbGetQuery(con, "
SELECT
    ROUND(AVG(n_authors), 2) AS promedio_autores_por_paper
FROM papers;
")

knitr::kable(consulta_1, caption = "Promedio de autores por artículo")
```

Table 7: Promedio de autores por artículo

promedio_autores_por_paper
3.96

El resultado muestra el número promedio de autores por artículo dentro de la revista analizada.

5.2 ¿Cuántos artículos están relacionados con Machine Learning?

```
consulta_2 <- dbGetQuery(con, "
SELECT
    COUNT(*) AS articulos_machine_learning
FROM papers
WHERE topic_label = 'Machine Learning';
")

knitr::kable(consulta_2, caption = "Cantidad de artículos relacionados con Machine Learning")
```

Table 8: Cantidad de artículos relacionados con Machine Learning

articulos_machine_learning
173

Esta consulta permite identificar cuántos artículos fueron clasificados automáticamente dentro de la categoría Machine Learning.

5.3 ¿Cuántos artículos están relacionados con IA Generativa?

```

consulta_3 <- dbGetQuery(con, "
SELECT
    COUNT(*) AS articulos_ia_generativa
FROM papers
WHERE topic_label = 'IA Generativa';
")

knitr::kable(consulta_3, caption = "Cantidad de artículos relacionados con IA Generativa")

```

Table 9: Cantidad de artículos relacionados con IA Generativa

articulos_ia_generativa
70

El resultado indica cuántos artículos contienen términos asociados con IA generativa, modelos de lenguaje, GPT, difusión o generación automática.

5.4 ¿Cuántos artículos están relacionados con otros temas estadísticos?

```

consulta_4 <- dbGetQuery(con, "
SELECT
    COUNT(*) AS articulos_estadistica
FROM papers
WHERE topic_label = 'Estadística';
")

knitr::kable(consulta_4, caption = "Cantidad de artículos relacionados con Estadística")

```

Table 10: Cantidad de artículos relacionados con Estadística

articulos_estadistica
15

Esta consulta muestra cuántos artículos fueron clasificados dentro de la categoría Estadística.

5.5 ¿Cuál es el número total de descargas de los artículos publicados en 2025?

```

consulta_5 <- dbGetQuery(con, "
SELECT
    SUM(downloads) AS total_descargas_2025
FROM papers
WHERE year = 2025;
")

knitr::kable(consulta_5, caption = "Total de descargas de artículos publicados en 2025")

```


Table 11: Total de descargas de artículos publicados en 2025

total_descargas_2025
524615323

El resultado resume la cantidad total de descargas registradas para los artículos del año 2025. En los casos donde no se pudo extraer la métrica, SQLite ignora los valores NULL al aplicar SUM.

5.6 ¿Cuál es el número promedio de referencias por artículo?

```
consulta_6 <- dbGetQuery(con, "
SELECT
    ROUND(AVG(n_references), 2) AS promedio_referencias_por_articulo
FROM papers;
")

knitr::kable(consulta_6, caption = "Promedio de referencias por artículo")
```

Table 12: Promedio de referencias por artículo

promedio_referencias_por_articulo
57.62

Esta consulta permite observar, en promedio, cuántas referencias bibliográficas tiene cada artículo de la revista.

5.7 ¿Cuál es la referencia que más se repite entre todos los artículos?

```
consulta_7 <- dbGetQuery(con, "
SELECT
    rt.reference_text_normalized AS referencia,
    COUNT(pr.paper_id) AS veces_repetida
FROM references_table rt
JOIN paper_references pr
    ON rt.reference_id = pr.reference_id
GROUP BY rt.reference_id, rt.reference_text_normalized
ORDER BY veces_repetida DESC
LIMIT 1;
")

knitr::kable(consulta_7, caption = "Referencia más repetida entre todos los artículos")
```

Table 13: Referencia más repetida entre todos los artículos

referencia	veces_repetida
Breiman, L. Random Forests. Mach. Learn. 2001, 45, 5-32. [Google Scholar] [CrossRef]	8

Esta consulta utiliza las tablas de referencias y la tabla intermedia **paper_references** para identificar cuál referencia aparece con mayor frecuencia en los artículos analizados.

5.8 ¿Cuál es el promedio de citas por artículo?

```
consulta_8 <- dbGetQuery(con, "
SELECT
    ROUND(AVG(citations), 2) AS promedio_citas_por_articulo
FROM papers;
")

knitr::kable(consulta_8, caption = "Promedio de citas por artículo")
```

Table 14: Promedio de citas por artículo

promedio_citas_por_articulo
NA

En esta consulta se calcula el promedio de citas registradas. Si los valores aparecen como NA o NULL, se debe a que esta métrica no estaba disponible directamente en el HTML estático de los artículos.

5.9 ¿Cuál es el paper con más citas?

```
consulta_9 <- dbGetQuery(con, "
SELECT
    title,
    doi,
    citations,
    topic_label
FROM papers
WHERE citations IS NOT NULL
ORDER BY citations DESC
LIMIT 1;
")

knitr::kable(consulta_9, caption = "Artículo con mayor número de citas")
```

Table 15: Artículo con mayor número de citas

title	doi	citations	topic_label
-------	-----	-----------	-------------

Esta consulta busca el artículo con mayor cantidad de citas. Si la tabla no muestra registros significa que no fue posible extraer citas directamente desde la página web.

5.10 ¿Cuál es el paper relacionado con Machine Learning, IA Generativa o Estadística con más citas?

```
consulta_10 <- dbGetQuery(con, "
SELECT
  title,
  doi,
  citations,
  topic_label
FROM papers
WHERE topic_label IN ('Machine Learning', 'IA Generativa', 'Estadística')
  AND citations IS NOT NULL
ORDER BY citations DESC
LIMIT 1;
")

knitr::kable(consulta_10, caption = "Artículo de Machine Learning, IA Generativa o Estadística con más citas")
```

Table 16: Artículo de Machine Learning, IA Generativa o Estadística con más citas

title	doi	citations	topic_label
-------	-----	-----------	-------------

Esta consulta filtra únicamente los artículos clasificados en las categorías principales del taller y busca el que tiene más citas registradas.

5.11 ¿Cuál es el paper relacionado con Machine Learning, IA Generativa o Estadística con más descargas?

```
consulta_11 <- dbGetQuery(con, "
SELECT
  title,
  doi,
  downloads,
  topic_label
FROM papers
WHERE topic_label IN ('Machine Learning', 'IA Generativa', 'Estadística')
  AND downloads IS NOT NULL
ORDER BY downloads DESC
```

```
LIMIT 1;
")
```

```
knitr::kable(consulta_11, caption = "Artículo de Machine Learning, IA Generativa o Estadística con más c
```

Table 17: Artículo de Machine Learning, IA Generativa o Estadística con más descargas

title	doi	downloadstopic_label
Reimagining Robots: The Future of Cybernetic Organisms with Energy-Efficient Designs	10.3390/bdcc9040504614479	Machine Learning

Esta consulta permite identificar cuál de los artículos clasificados en las categorías principales presenta el mayor número de descargas registradas.

5.12 Archivo SQL consolidado

Además de ejecutar las consultas dentro del informe, se generó un archivo `.sql` independiente con las once consultas solicitadas.

El archivo generado se llama:

```
output/bdcc_2025_consultas.sql
```

6. Hallazgos

Uno de los hallazgos principales fue que la mayor parte de los artículos publicados durante 2025 se relacionan con temas de **Machine Learning** e **IA Generativa**. Esto evidencia la fuerte presencia actual de investigaciones enfocadas en inteligencia artificial, aprendizaje profundo y modelos generativos dentro de la producción científica de la revista.

También se observó que muchos artículos presentan una cantidad considerable de referencias bibliográficas, lo que sugiere que estas áreas poseen una producción científica amplia y en constante crecimiento.

En relación con la estructura de autoría, se encontró que la mayoría de artículos fueron desarrollados por múltiples autores lo que refleja que es un campo colaborativo.

Otro hallazgo importante fue la existencia de referencias bibliográficas repetidas entre artículos diferentes, lo cual indica la presencia de trabajos base o investigaciones utilizadas como fundamento teórico dentro de la revista.

7. Limitaciones

Durante el desarrollo del scraping se encontraron varias limitaciones relacionadas con la disponibilidad y estructura de los datos publicados en el sitio web de MDPI.

Una de las principales limitaciones fue la extracción de métricas dinámicas como citas y visualizaciones. En muchos artículos esta información no se encontraba disponible directamente dentro del HTML estático, sino que aparentemente se cargaba mediante componentes dinámicos o servicios externos. Debido a esto varios registros quedaron almacenados con valores NA.

Otra limitación importante estuvo relacionada con las restricciones propias del sitio web frente a solicitudes automatizadas. Para reducir el riesgo de bloqueo fue necesario utilizar encabezados HTTP similares a los de un navegador real y aplicar pausas entre solicitudes.

También debe considerarse que la clasificación temática realizada fue basada en reglas simples de palabras clave. Aunque esto es reproducible para el propósito del taller no reemplaza métodos avanzados de clasificación semántica o procesamiento de lenguaje natural.

8. Conclusiones

Durante el desarrollo del taller se logró construir un proceso completo de abstracción, transformación y almacenamiento de información académica utilizando técnicas de web scraping y bases de datos relacionales.

A partir de la revista *Big Data and Cognitive Computing* se extrajeron artículos científicos publicados durante el año 2025 junto con información relacionada con autores, referencias bibliográficas y métricas disponibles.

Uno de los principales retos encontrados fue la extracción de métricas dinámicas como citas y visualizaciones, ya que parte de esta información no se encontraba directamente disponible dentro del HTML estático de las páginas. Por esta razón algunos valores permanecieron como ‘NA, priorizando mantener la integridad y trazabilidad de los datos extraídos.

También se implementó una clasificación temática utilizando reglas basadas en palabras clave, lo que permitió agrupar los artículos en categorías relacionadas con Machine Learning, IA Generativa, Estadística y Otros.

Finalmente la información fue organizada en una base de datos SQLite utilizando un modelo relacional compuesto por tablas para artículos, autores y referencias. Esto permitió ejecutar consultas SQL para analizar el contenido extraído y responder las preguntas planteadas en el taller.