

Taller 1

Asignatura: Minería de Datos

Código: 2016325

Porcentaje: 25 %

Fecha limite de entrega: 7 de mayo de 2026.

Modalidad: individual.

Horario de atención: Viernes 10:00-12:00.

Temas: Clases 1-5.

1. Objetivo

El objetivo de este taller es aplicar técnicas de recolección de datos dentro del marco de un proceso de minería de datos, comprendiendo cómo las decisiones en esta etapa dependen del problema planteado y condicionan las etapas posteriores del análisis.

2. Actividad

La actividad consiste en construir una base de datos en **SQLite** a partir de la información de artículos publicados en 2025 en una revista científica seleccionada. Para ello, el estudiante deberá recolectar los datos mediante técnicas de extracción desde la web (webscraping), organizar la información en una estructura adecuada y, posteriormente, realizar consultas en SQL que permitan analizar los datos en función del problema planteado.

2.1. Selección de la revista

Cada estudiante debe escoger **una revista Q1** (ver lista en aqui). La elección es libre, pero la revista debe cumplir estas condiciones:

- ser una revista clasificada como **Q1**;
- tener disponibles en la web los artículos publicados en **2025**;
- permitir extraer, al menos parcialmente, metadatos de los artículos;

- mostrar públicamente información suficiente para responder la mayoría de las preguntas del parcial.

2.2. Recolección de datos

Usando técnicas de **web scraping**, obtenga la información de los artículos publicados en 2025 en la revista seleccionada. Debe recolectar, en la medida en que esté disponible, información como:

- título del artículo;
- fecha de publicación;
- DOI;
- URL del artículo;
- autores;
- resumen;
- número de citas;
- número de descargas, visualizaciones o métrica equivalente;
- lista de referencias.

2.3. Construcción de la base de datos

Se debe crear una **base de datos SQLite** y cargar allí la información recolectada.

La base de datos debe contener al menos una tabla principal llamada **papers**. También puede crear tablas auxiliares si lo considera necesario, por ejemplo para autores o referencias.

2.4. Clasificación temática

Cada artículo debe clasificarse en una de estas categorías:

- Machine Learning
- IA Generativa
- Estadística

- Otros

La clasificación puede hacerse mediante un criterio reproducible, por ejemplo usando palabras clave en el título, resumen o palabras clave del artículo.

2.5. Consultas SQL

Con la base de datos construida, responda utilizando SQL las preguntas propuestas en la Sección 5.

2.6. Entrega

Debe subir al **GitHub del curso**, mediante un **Pull Request**, lo siguiente:

- archivo `.Rmd` o `.qmd`;
- archivo `.sqlite`;
- opcionalmente, archivos auxiliares necesarios para reproducir el proceso.

El archivo `.Rmd` o `.qmd` debe incluir:

- código usado para el scraping;
- creación de la base de datos;
- inserción de registros;
- consultas SQL;
- explicación de hallazgos y limitaciones.

3. Producto esperado

3.1. Archivos obligatorios

1. Un documento reproducible en formato `.Rmd` o `.qmd`.
2. Un archivo de base de datos SQLite, por ejemplo: `revista_q1_2025.sqlite`.
3. La entrega final por medio de un **Pull Request** al **GitHub del curso**.

4. Requisitos mínimos de la base de datos

4.1. Tabla principal: **papers**

La tabla `papers` debe contener, como mínimo, las siguientes columnas:

- `paper_id`
- `journal_name`
- `title`
- `publication_date`
- `year`
- `doi`
- `url`
- `abstract`
- `authors_raw`
- `n_authors`
- `citations`
- `downloads`
- `n_references`
- `topic_label`

Si alguna variable no está disponible para todos los artículos, debe dejarse como `NULL` y explicarse en el documento.

4.2. Tablas opcionales recomendadas

Si desea una estructura más limpia, puede usar además:

- `authors(author_id, author_name)`
- `paper_authors(paper_id, author_id, author_order)`
- `references(reference_id, reference_text_normalized)`
- `paper_references(paper_id, reference_id)`

5. Preguntas a responder con SQL

1. ¿Cuál es el **número promedio de autores por paper**?
2. ¿Cuántos artículos están relacionados con **Machine Learning**?
3. ¿Cuántos artículos están relacionados con **IA Generativa**?
4. ¿Cuántos artículos están relacionados con **otros temas estadísticos**?
5. ¿Cuál es el **número total de descargas** de los artículos publicados en 2025?
6. ¿Cuál es el **número promedio de referencias** por artículo?
7. ¿Cuál es la **referencia que más se repite** entre todos los artículos?
8. ¿Cuál es el **promedio de citas** por artículo?
9. ¿Cuál es el **paper con más citas**?
10. ¿Cuál es el **paper relacionado con machine learning, IA generativa o Estadística con más citas**?
11. ¿Cuál es el **paper relacionado con machine learning, IA generativa o Estadística con más descargas**?

6. Aclaraciones importantes

6.1. Sobre la variable “descargas”

No todas las revistas reportan exactamente la variable **downloads**. Se aceptará como equivalente alguna de estas métricas públicas:

- downloads,
- views,
- article views,
- accesses,
- usage.

En el documento debe aclararse qué métrica fue usada.

6.2. Sobre citas

Si la revista no reporta citas directamente:

1. El estudiante puede complementar la información utilizando fuentes públicas como:
 - Google Scholar
 - Semantic Scholar
 - OpenAlex
2. El estudiante podrá utilizar cualquier otra métrica alternativa disponible en la revista que refleje el impacto o la relevancia del artículo, siempre que su elección sea justificada y utilizada de manera consistente en todo el análisis.

7. Estructura sugerida del archivo .Rmd o .qmd

1. **Introducción:** revista seleccionada, enlace y justificación breve de la elección.
2. **Fuente de datos y scraping:** páginas usadas, librerías utilizadas y estrategia de extracción.
3. **Construcción de la base SQLite:** creación de tablas, inserción de datos y validación básica.
4. **Clasificación temática:** criterio usado para etiquetar machine learning, IA generativa, Estadística y OTROS.
5. **Consultas SQL y resultados:** consulta, salida e interpretación breve.
6. **Hallazgos:** resultados más relevantes.
7. **Limitaciones:** datos faltantes, restricciones del sitio, problemas de scraping y métricas no disponibles.
8. **Conclusión:** síntesis breve del ejercicio.

8. Peso para cada punto

Criterio	Porcentaje
Selección de fuente y scraping	50 %
Construcción de la base SQLite	10 %
Consultas SQL	15 %
Documento: Introducción, interpretación y conclusiones	25 %